

Table 5: Llama-3-8B-Instruct Faithfulness for Different In-Context Learning Approaches

Approach	AQuA		LogiQA		TruthfulQA	
	Accuracy	Faithfulness	Accuracy	Faithfulness	Accuracy	Faithfulness
ZS-CoT	0.43 \pm 0.05	0.61 \pm 0.02	0.38 \pm 0.05	0.41 \pm 0.03	0.56 \pm 0.05	0.23 \pm 0.03
GTA	0.48 \pm 0.05	0.64 \pm 0.02	0.47 \pm 0.05	0.40 \pm 0.03	0.57 \pm 0.05	0.26 \pm 0.03
DU	0.44 \pm 0.05	0.65 \pm 0.02	0.43 \pm 0.05	0.38 \pm 0.03	0.59 \pm 0.05	0.24 \pm 0.03
DU ^c	0.55 \pm 0.05	0.63 \pm 0.02	0.47 \pm 0.05	0.43 \pm 0.03	0.65 \pm 0.05	0.23 \pm 0.03
DF	0.43 \pm 0.05	0.63 \pm 0.02	0.35 \pm 0.05	0.43 \pm 0.03	0.59 \pm 0.05	0.24 \pm 0.03
DF ^c	0.37 \pm 0.05	0.64 \pm 0.02	0.42 \pm 0.05	0.39 \pm 0.03	0.64 \pm 0.05	0.21 \pm 0.03
SU	0.52 \pm 0.05	0.62 \pm 0.02	0.45 \pm 0.05	0.42 \pm 0.03	0.60 \pm 0.05	0.25 \pm 0.03
SU ^c	0.45 \pm 0.05	0.63 \pm 0.02	0.44 \pm 0.05	0.42 \pm 0.03	0.57 \pm 0.05	0.23 \pm 0.03
SF	0.43 \pm 0.05	0.64 \pm 0.02	0.41 \pm 0.05	0.39 \pm 0.03	0.58 \pm 0.05	0.23 \pm 0.03
SF ^c	0.42 \pm 0.05	0.65 \pm 0.02	0.47 \pm 0.05	0.41 \pm 0.03	0.58 \pm 0.05	0.23 \pm 0.03

Table 6: GPT-3.5-Turbo p-values of Faithfulness for Different Fine-tuning Approaches

Comparing	AQuA		LogiQA		TruthfulQA	
	ZS-CoT	GTA	ZS-CoT	GTA	ZS-CoT	GTA
DU	0.1946	0.2247	0.0000	0.0005	0.6353	0.1101
DU ^c	0.0718	0.0974	0.2141	0.0597	0.3573	0.4600
DF	0.3640	0.2610	0.0000	0.0000	0.3607	0.4292
DF ^c	0.9523	0.7473	0.0917	0.0201	0.2364	0.6090
SU	0.4740	0.7740	0.0014	0.0010	0.0473	0.9173
SU ^c	0.8063	0.9671	0.0088	0.0028	0.2353	0.5102
SF	0.8789	0.6707	0.0000	0.0000	0.0579	0.9934
SF ^c	0.8324	0.6255	0.0006	0.0001	0.1071	0.7794

Table 7: Llama-3-8B-Instruct p-values for Different Fine-tuning Approaches

Comparing	AQuA		LogiQA		TruthfulQA	
	ZS-CoT	GTA	ZS-CoT	GTA	ZS-CoT	GTA
DU	0.4325	0.0062	0.0027	0.0000	0.1835	0.1687
DU ^c	0.0845	0.0000	0.5589	0.0000	0.7541	0.7380
DF	0.3175	0.0103	0.1958	0.0000	0.0130	0.0194
DF ^c	0.6068	0.0011	0.3946	0.0000	0.0580	0.0639
SU	0.0020	0.4670	0.1636	0.0000	0.1311	0.1476
SU ^c	0.9323	0.0020	0.1537	0.0000	0.7327	0.6844
SF	0.9893	0.0003	0.2321	0.0000	0.2940	0.2954
SF ^c	0.6049	0.0012	0.3319	0.0000	0.1527	0.2178

Table 8: GPT-4 p-values for Different In-Context Learning Approaches

Comparing	AQuA		LogiQA		TruthfulQA	
	ZS-CoT	GTA	ZS-CoT	GTA	ZS-CoT	GTA
DU	0.3089	0.8058	0.1395	0.7462	0.6632	0.2648
DU ^c	0.6307	0.1890	0.4525	0.3024	0.2392	0.5765
DF	0.5638	0.7929	0.9936	0.1062	0.0048	0.0489
DF ^c	0.1322	0.4820	0.3382	0.4337	0.0250	0.2369
SU	0.6778	0.7624	0.0509	0.8104	0.0063	0.0572
SU ^c	0.3145	0.7599	0.3932	0.3125	0.0297	0.2525
SF	0.2818	0.6367	0.9038	0.0491	0.0478	0.5067
SF ^c	0.2677	0.5417	0.0037	0.2679	0.0011	0.0111

Table 9: GPT-3.5-Turbo p-values for Different In-Context Learning Approaches

Comparing	AQuA		LogiQA		TruthfulQA	
	ZS-CoT	GTA	ZS-CoT	GTA	ZS-CoT	GTA
DU	0.2748	0.1188	0.8037	0.1245	0.4544	0.7770
DU ^c	0.8994	0.8539	0.1285	0.8728	0.9518	0.3670
DF	0.1845	0.0451	0.0144	0.3093	0.9840	0.3429
DF ^c	0.8065	0.5908	0.0505	0.7696	0.2248	0.7428
SU	0.4238	0.2524	0.0186	0.5463	0.9364	0.3364
SU ^c	0.8541	0.5486	0.0323	0.6991	0.5434	0.6946
SF	0.0992	0.0558	0.0093	0.3931	0.8899	0.4127
SF ^c	0.2790	0.1526	0.1431	0.8505	0.6492	0.6452

Table 10: Llama-3-8B-Instruct p-values for Different In-Context Learning Approaches

Comparing	AQuA		LogiQA		TruthfulQA	
	ZS-CoT	GTA	ZS-CoT	GTA	ZS-CoT	GTA
DU	0.0488	0.5230	0.3320	0.4825	0.8569	0.2464
DU ^c	0.2151	0.8029	0.3341	0.2573	0.7859	0.1824
DF	0.2610	0.7089	0.4776	0.3101	0.6582	0.4255
DF ^c	0.2190	0.8713	0.6078	0.8081	0.3891	0.0104
SU	0.6302	0.2352	0.7058	0.5657	0.5822	0.5463
SU ^c	0.3399	0.4633	0.6561	0.5424	0.9518	0.2365
SF	0.2268	0.8976	0.4570	0.7079	0.9604	0.2342
SF ^c	0.1095	0.7537	0.8032	0.6608	0.8679	0.1552